

回顾上节课内容:

1. 奇异值分解定理(SVD):

给定  $A \in M_{m \times n}(\mathbb{R})$  秩为  $r$ , 存在  $m$  阶正交矩阵  $U$  和  $n$  阶正交矩阵  $V$  使得  $A = U\Sigma V^T$ ,

$$\text{其中, } \Sigma = \begin{bmatrix} \Sigma_r & O_{r \times (n-r)} \\ O_{(m-r) \times r} & O_{(m-r) \times (n-r)} \end{bmatrix}, \Sigma_r = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \in M_r(\mathbb{R})$$

且  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ .  按重要性顺序对奇异值排序

$\sigma_1, \dots, \sigma_r$  称为  $A$  的奇异值

步骤: 1) 对半正定对称矩阵  $A^T A$  做谱分解, 特征值  $\lambda$ , 特征向量  $v$

2) 令  $\sigma = \sqrt{\lambda}$ , 得到奇异值

3) 令  $u = \frac{Av}{\sigma}$

4) 将  $u$  扩充为  $\mathbb{R}^m$  的一组标准正交基

## 2. 简化奇异值分解:

$A \in M_{m \times n}(\mathbb{R})$  秩为  $r$ . 由奇异值分解

$$A = U\Sigma V^T = [\mathbf{u}_1, \dots, \mathbf{u}_m] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \\ & & & 0 \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{bmatrix}$$

$$= \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \dots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$


$$\text{令 } U_r = [\mathbf{u}_1, \dots, \mathbf{u}_r], \Sigma_r = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}, V_r = [\mathbf{v}_1, \dots, \mathbf{v}_r]$$

$A = U_r \Sigma_r V_r^T$  称为  $A$  的**简化奇异值分解**

## 3. 奇异值分解的几何的解释

1) 映射复合的角度

2) 空间分解的角度



#### 4. 广义逆与最小二乘法

广义逆的定义:  $A \in M_{m \times n}(\mathbb{R}) \rightsquigarrow A^+ \in M_{n \times m}(\mathbb{R})$

线性映射角度  $A: \mathbb{R}^n \rightarrow \mathbb{R}^m \rightsquigarrow A^+: \mathbb{R}^m \rightarrow \mathbb{R}^n$

设  $\Sigma = \begin{bmatrix} \Sigma_r & O_{r \times (n-r)} \\ O_{(m-r) \times r} & O_{(m-r) \times (n-r)} \end{bmatrix} \in M_{m \times n}(\mathbb{R})$ , 其中  $\Sigma_r = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \in M_r(\mathbb{R})$


令  $\Sigma^+ := \begin{bmatrix} \Sigma_r^+ & O_{r \times (m-r)} \\ O_{(n-r) \times r} & O_{(n-r) \times (m-r)} \end{bmatrix} \in M_{n \times m}(\mathbb{R})$ , 其中  $\Sigma_r^+ = \begin{bmatrix} \sigma_1^{-1} & & \\ & \ddots & \\ & & \sigma_r^{-1} \end{bmatrix} \in M_r(\mathbb{R})$

$A \in M_{m \times n}(\mathbb{R})$ , 有奇异值分解  $A = U\Sigma V^T$ 。定义  $A$  的广义逆:

$$A^+ = V\Sigma^+U^T \in M_{n \times m}(\mathbb{R}).$$

于是对于可逆方阵, 广义逆就是矩阵的逆。

## 广义逆与正交投影:



$$A^+(\sigma_1 \mathbf{u}_1) = \mathbf{v}_1, \dots, A^+(\sigma_r \mathbf{u}_r) = \mathbf{v}_r; A^+(\mathbf{u}_{r+1}) = \dots = A^+(\mathbf{u}_m) = \mathbf{0}.$$

问题:  $A^+A$ 在 $\mathcal{R}(A^T)$ 和 $\mathcal{N}(A)$ 上的作用是什么?

$AA^+$ 在 $\mathcal{R}(A)$ 和 $\mathcal{N}(A^T)$ 上的作用是什么?

命题:

$\pi$

- (1)  $A^+A$ 为在 $A$ 的行空间上的正交投影矩阵。
- (2)  $I_n - A^+A$ 为在 $A$ 的零空间上的正交投影矩阵。
- (3)  $AA^+$ 为在 $A$ 的列空间上的正交投影矩阵。
- (4)  $I_m - AA^+$ 为在 $A$ 的左零空间上的正交投影矩阵。

小结:

计算在 $A$ 的列空间上的正交投影矩阵

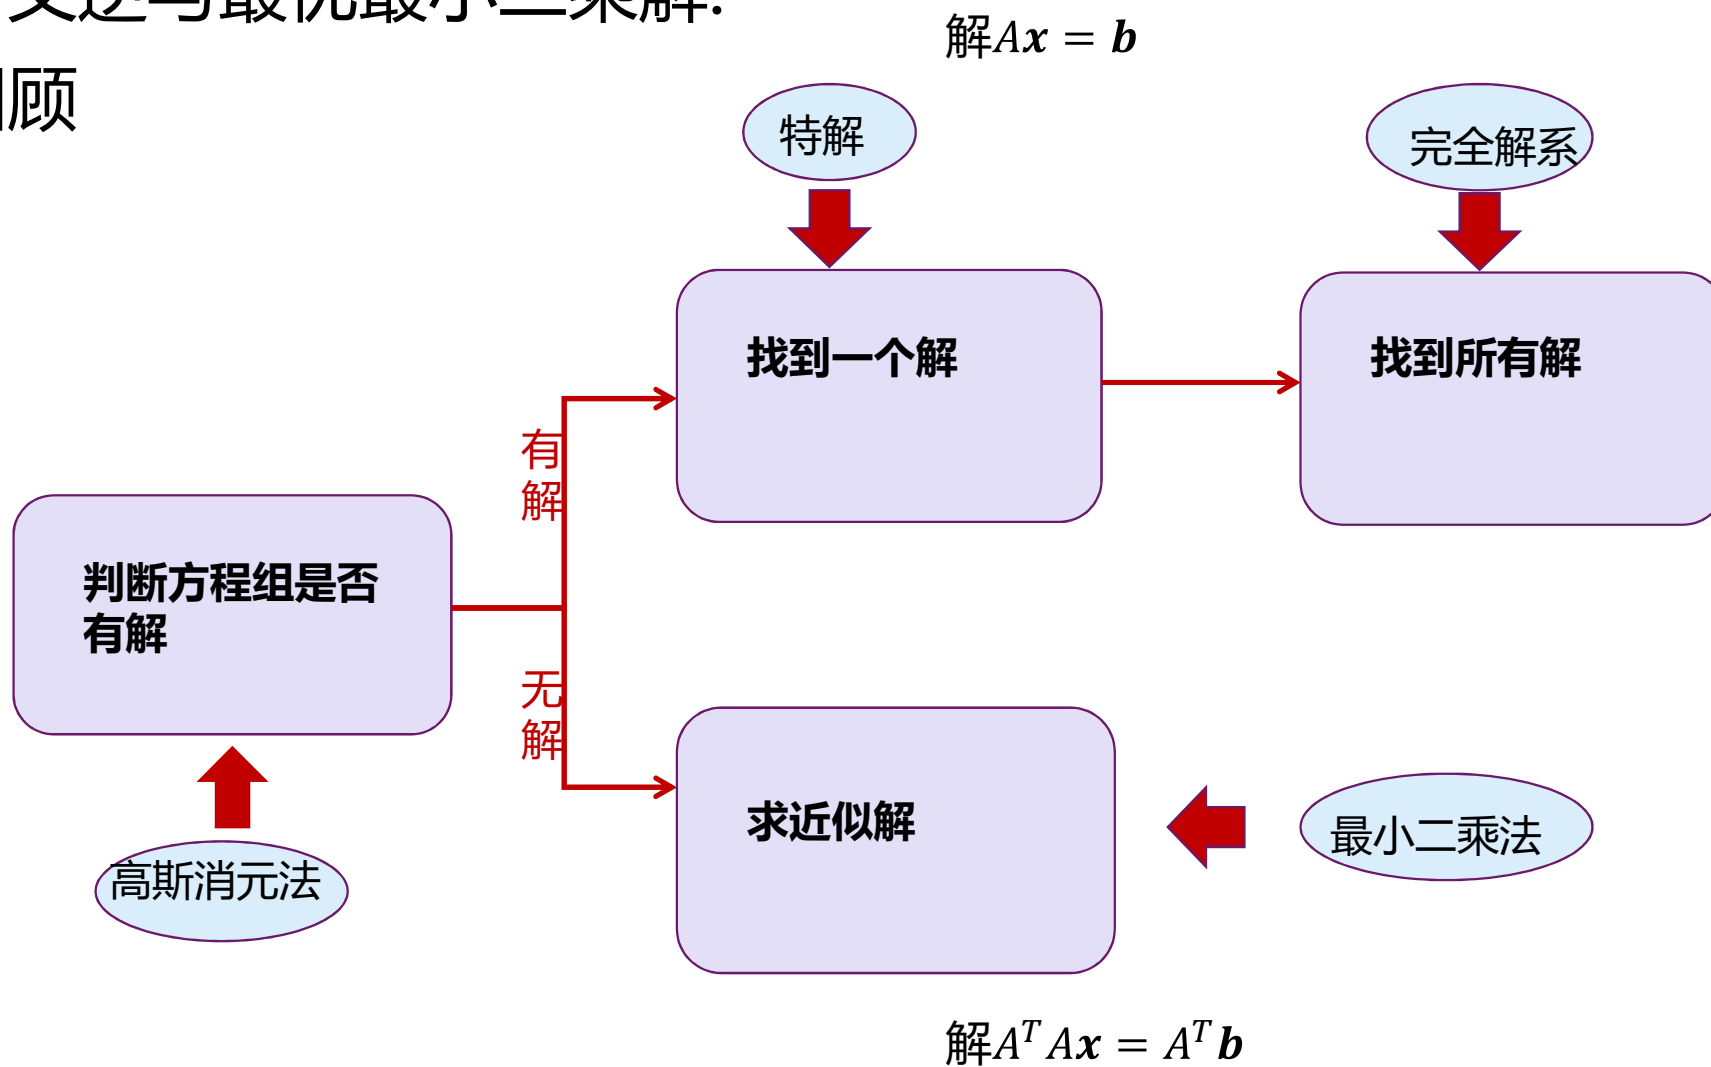
(1) 列满秩矩阵:  $A(A^T A)^{-1} A^T$


(2) 一般矩阵:

a. 高斯消元找主列, 利用主列构成的列满秩矩阵计算

b.  $AA^+$ , 需要计算奇异值分解

# 广义逆与最优最小二乘解: 回顾



$\pi$ 

$x^+$  满足  $x^+ \in \mathcal{R}(A^T)$  且  $A^T A x^+ = A^T b$



广义逆与最优最小二乘解:

$x^+ = A^+ b$  为方程  $Ax = b$  的最优最小二乘解。


证明:

只需说明(1)  $x^+ = A^+ b$  满足  $A^T A x^+ = A^T b$  (2)  $x^+ \in \mathcal{R}(A^T)$

(1) 首先说明  $A^+ b$  为最小二乘解, 即  $A^+ b$  满足  $A(A^+ b) = p$   
 $A(A^+ b) = (AA^+)b$

$AA^+$  为在  $\mathcal{R}(A)$  上的正交投影矩阵, 因此,  $(AA^+)b = p$

$$(2) \mathbf{x}^+ = A^+ \mathbf{b} = A^+ (\mathbf{p} + \mathbf{e}) = A^+ \mathbf{p} + A^+ \mathbf{e} = A^+ \mathbf{p} \in \mathcal{R}(A^T).$$



图片来源: Gilbert Strang, Introduction to linear algebra, 5<sup>th</sup> edition

(d) 矩阵的谱范数（考试内容）与低秩逼近（非考试内容）

矩阵的低秩逼近在实际中具有广泛应用

回顾在奇异值分解中,  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ .

$$A = U\Sigma V^T = [\mathbf{u}_1, \dots, \mathbf{u}_m] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{bmatrix}$$

$$= \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \dots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$

对  $k \leq r$ , 定义  $A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \dots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$

$$\text{令 } U_k = [\mathbf{u}_1, \dots, \mathbf{u}_k], \Sigma_k = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_k \end{bmatrix}, V_k = [\mathbf{v}_1, \dots, \mathbf{v}_k].$$

$$A_k = U_k \Sigma_k V_k^T$$

容易看出:  $A_k = U_k \Sigma_k V_k^T = [\mathbf{u}_1, \dots, \mathbf{u}_m] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_k \\ & & & \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{bmatrix}$

由于 $U, V$ 可逆,  $\text{rank}(A_k) = k$ .

$A_k$ 称为矩阵 $A$ 的秩为 $k$ 的逼近。

Eckart-Young-Mirsky定理:  $A_k$ 是所有秩小于等于 $k$ 的 $m \times n$ 阶矩阵中“距离” $A$ 最近的矩阵。

下面我们给出距离的定义

回顾: 实数(或复数)有了绝对值(或模), 我们定义两个数 $a, b$ 之间的距离为 $|a - b|$ ;

## 矩阵范数与矩阵距离:

一个函数  $\|-\|: M_{m \times n}(\mathbb{R}) \rightarrow \mathbb{R}_{\geq 0}$  称为是一个范数(norm), 如果  $\|-\|$  满足

$$(1) \|A + B\| \leq \|A\| + \|B\|$$

$$(2) \|cA\| = |c|\|A\|, c \in \mathbb{R},$$

$$(3) \|A\| = 0 \text{ 当且仅当 } A = O_{m \times n}.$$

固定了一个矩阵范数, 可以定义两个矩阵的距离:

对  $A, B \in M_{m \times n}(\mathbb{R})$ , 定义  $d(A, B) = \|A - B\|$ .

根据范数的性质我们容易得到:

$$(1) d(A, B) = 0 \text{ 当且仅当 } A = B;$$

$$(2) d(A, B) = d(B, A);$$

$$(3) d(A, C) \leq d(A, B) + d(B, C) \text{ (三角不等式)}$$

谱范数的定义:

定义谱范数  $\|\cdot\|: M_{m \times n}(\mathbb{R}) \rightarrow \mathbb{R}_{\geq 0}$ ,

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{x, \|x\|=1} \|Ax\|,$$

这里  $\|Ax\|, \|x\|$  分别为向量  $Ax, x$  的长度。

当  $n = 1$  时,  $A$  是列向量,  $\|A\|$  就是向量的长度。

命题：谱范数是个范数，即

$$(1) \|A + B\| \leq \|A\| + \|B\|.$$

$$(2) \|cA\| = |c|\|A\|,$$

$$(3) \|A\| = 0 \text{ 当且仅当 } A = O_{m \times n},$$

$$(4) \|AB\| \leq \|A\|\|B\|. \quad \leftarrow \text{矩阵乘法在谱范数下是连续的}$$

证明：

$$(1) \frac{\|(A+B)x\|}{\|x\|} = \frac{\|Ax+Bx\|}{\|x\|} \leq \frac{\|Ax\|+\|Bx\|}{\|x\|} = \frac{\|Ax\|}{\|x\|} + \frac{\|Bx\|}{\|x\|},$$

$$\max \frac{\|(A+B)x\|}{\|x\|} \leq \max \left( \frac{\|Ax\|}{\|x\|} + \frac{\|Bx\|}{\|x\|} \right) \leq \max \frac{\|Ax\|}{\|x\|} + \max \frac{\|Bx\|}{\|x\|}$$

因此,  $\|A + B\| \leq \|A\| + \|B\|$

$$(2) \|cA\| = |c|\|A\|$$

$$\text{证明: } \frac{\|(cA)x\|}{\|x\|} = \frac{\|cAx\|}{\|x\|} = |c| \frac{\|Ax\|}{\|x\|},$$

$$\text{因此, } \|cA\| = |c|\|A\|$$

$$(3) \|A\| = 0 \text{ 当且仅当 } A = O_{m \times n},$$

证明: 如果  $A = O_{mn}$ , 则  $\|A\| = 0$ 。

反之, 如果  $\|A\| = 0$ , 那么  $\|Ax\| = 0, \forall x \neq \mathbf{0}$ .

因此,  $Ax = \mathbf{0}, \forall x \neq \mathbf{0}$ , 于是  $A = O_{mn}$ .

$$(4) \|AB\| \leq \|A\|\|B\|$$

证明:

$$\|AB\| = \max \frac{\|(AB)x\|}{\|x\|} = \max \left( \frac{\|ABx\|}{\|Bx\|} \frac{\|Bx\|}{\|x\|} \right) \leq \max \left( \frac{\|ABx\|}{\|Bx\|} \right) \max \left( \frac{\|Bx\|}{\|x\|} \right) \leq \|A\|\|B\|.$$



Eckart-Young-Mirsky定理:

$\pi$

令 $A_k$ 为 $A$ 的秩 $k$ 逼近, 则对任意秩 $\leq k$ 的矩阵 $B \in M_{m \times n}(\mathbb{R})$

$$d(A, A_k) = \|A - A_k\| \leq \|A - B\| = d(A, B).$$

为了证明这个定理, 我们建立矩阵谱范数与奇异值的关系

工具: Rayleigh商

谱范数与奇异值:

$\pi$  命题:  $\|A\| = \sigma_1$  是  $A$  的最大奇异值。

回顾Rayleigh商: 给定实对称矩阵  $S$ , 特征值为  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ,

相应的特征向量为  $q_1, \dots, q_n$ , 即  $S = Q\Lambda Q^T$ , 则  $\lambda_1 = \max_{x \neq 0} \frac{x^T S x}{x^T x}$

命题的证明:

令  $S = A^T A = V\Lambda V^T$ ,  $\Lambda = \text{Diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0)$ ,  $V = [v_1, \dots, v_n]$ .

由Rayleigh商,  $\sigma_1^2 = \max_{x \neq 0} \frac{x^T A^T A x}{x^T x} = \max_{x \neq 0} \frac{\|Ax\|^2}{\|x\|^2}$ .

于是  $\sigma_1 = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \|A\|$ .

推论:

$\pi$

$$\|A - A_k\| = \sigma_{k+1}.$$

证明:

$$A - A_k = \sigma_{k+1} \mathbf{u}_{k+1} \mathbf{v}_{k+1}^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$$

是 $A - A_k$ 的简化奇异值分解,

其最大奇异值为 $\sigma_{k+1}$ .

Eckart-Young-Mirsky定理:

对任意秩 $\leq k$ 的 $m \times n$ 阶矩阵 $B$ ,  $\|A - A_k\| \leq \|A - B\|$

证明:

设 $B \in M_{m \times n}(\mathbb{R})$ ,  $\text{rank}(B) \leq k$ .

首先证明存在非零向量 $\mathbf{x}_0 \in \mathcal{N}(B) \cap \mathcal{R}(A_{k+1}^T)$ .

由于 $\text{rank}(B) \leq k$ ,  $\dim \mathcal{N}(B) \geq n - k$ . 因此,

$$\dim \mathcal{N}(B) + \dim \mathcal{R}(A_{k+1}^T) \geq n - k + k + 1 = n + 1.$$

由维数公式

$$\begin{aligned} \dim \mathcal{N}(B) \cap \mathcal{R}(A_{k+1}^T) &= \dim \mathcal{N}(B) + \dim \mathcal{R}(A_{k+1}^T) - \dim(\mathcal{N}(B) + \mathcal{R}(A_{k+1}^T)) \\ &\geq n + 1 - n = 1. \end{aligned}$$

因此, 存在非零向量 $\mathbf{x}_0 \in \mathcal{N}(B) \cap \mathcal{R}(A_{k+1}^T)$ .

由于 $\mathbf{v}_1, \dots, \mathbf{v}_{k+1}$ 构成 $\mathcal{R}(A_{k+1}^T)$ 的一组标准正交基,


存在 $c_1, \dots, c_{k+1} \in \mathbb{R}$ 使得 $\mathbf{x}_0 = c_1 \mathbf{v}_1 + \dots + c_{k+1} \mathbf{v}_{k+1}$ .

$\pi$ 

$$\begin{aligned}\|A - B\| &\geq \frac{\|(A - B)\mathbf{x}_0\|}{\|\mathbf{x}_0\|} \stackrel{\text{red arrow}}{=} \frac{\|A\mathbf{x}_0\|}{\|\mathbf{x}_0\|} \quad \mathbf{x}_0 \in \mathcal{N}(B) \\ &= \frac{\|A(c_1\mathbf{v}_1 + \dots + c_{k+1}\mathbf{v}_{k+1})\|}{\|c_1\mathbf{v}_1 + \dots + c_{k+1}\mathbf{v}_{k+1}\|} \\ &= \frac{\|\sigma_1 c_1 \mathbf{u}_1 + \dots + \sigma_{k+1} c_{k+1} \mathbf{u}_{k+1}\|}{\|c_1\mathbf{v}_1 + \dots + c_{k+1}\mathbf{v}_{k+1}\|} \\ &= \frac{\sqrt{|\sigma_1 c_1|^2 + \dots + |\sigma_{k+1} c_{k+1}|^2}}{\sqrt{c_1^2 + \dots + c_{k+1}^2}} \\ &\geq \frac{\sqrt{|\sigma_{k+1} c_1|^2 + \dots + |\sigma_{k+1} c_{k+1}|^2}}{\sqrt{c_1^2 + \dots + c_{k+1}^2}} \\ &= \sigma_{k+1} = \|A - A_k\|.\end{aligned}$$

$$\begin{aligned}A &= U\Sigma V^T \\ AV &= U\Sigma\end{aligned}$$

# 总复习I: 线性代数基本定理:



## 线性代数基本定理(v.2.0):

$\pi$

$$A \in M_{m \times n}(\mathbb{R})$$

$$(1) \operatorname{rank}(A) \leq \min(m, n).$$

(2) 四个基本子空间的维数

$$\text{行空间 } \mathcal{R}(A^T): \dim \mathcal{R}(A^T) = \operatorname{rank}(A)$$

$$\text{零空间 } \mathcal{N}(A): \dim \mathcal{N}(A) = n - \operatorname{rank}(A)$$

$$\text{列空间 } \mathcal{R}(A): \dim \mathcal{R}(A) = \operatorname{rank}(A)$$

$$\text{左零空间 } \mathcal{N}(A^T): \dim \mathcal{N}(A^T) = m - \operatorname{rank}(A)$$

(3) 四个基本子空间的一组基

由  $\operatorname{rref}(A)$  的非零行给出

由规范基础解系给出


由  $A$  的主元列给出

由  $EA = \operatorname{rref}(A)$  中  $E$  的后  $m - \operatorname{rank}(A)$  行给出

$$(4) \text{ 空间分解: } \mathbb{R}^n = \mathcal{N}(A) + \mathcal{R}(A^T), \mathbb{R}^m = \mathcal{N}(A^T) + \mathcal{R}(A)$$

$$(5) \mathcal{N}(A) = \mathcal{R}(A^T)^\perp, \mathcal{N}(A^T) = \mathcal{R}(A)^\perp$$

$\pi$




$$A^T A x = A^T b \Leftrightarrow A x = p$$



(6) 奇异值分解:  $\mathcal{R}(A^T), \mathcal{N}(A), \mathcal{R}(A), \mathcal{N}(A^T)$  存在标准正交基

$\{v_1, \dots, v_r\}, \{v_{r+1}, \dots, v_n\}, \{u_1, \dots, u_r\}, \{u_{r+1}, \dots, u_m\}$  使得有  $\sigma_i > 0, 1 \leq i \leq r$  满足  $Av_1 = \sigma_1 u_1, Av_2 = \sigma_2 u_2, \dots, Av_r = \sigma_r u_r, Av_{r+1} = 0, \dots, Av_n = 0$

$$A = U\Sigma V^T$$



(7) 令  $U = [\mathbf{u}_1, \dots, \mathbf{u}_m]$ ,  $V = [\mathbf{v}_1, \dots, \mathbf{v}_n]$ .

$A^+ = V\Sigma^+U^T \in M_{n \times m}(\mathbb{R})$  为  $A$  的广义逆。

(8)  $\mathbf{b} \in \mathbb{R}^m$  在  $\mathcal{R}(A)$  上的正交投影:

如果  $A$  为列满秩矩阵, 正交投影  $\mathbf{p} = A(A^T A)^{-1} A^T \mathbf{b}$ .

对于一般矩阵  $A$ ,  $\mathbf{p} = AA^+ \mathbf{b}$ .

(9)  $A\mathbf{x} = \mathbf{b}$  的最小二乘解与最优最小二乘解:

当  $A$  为列满秩矩阵时,  $(A^T A)^{-1} A^T \mathbf{b}$  是最小二乘解也是最优最小二乘解。

对于一般矩阵  $A$ , 最优最小二乘解  $\mathbf{x}^+ = A^+ \mathbf{b}$ .

集合  $\mathbf{x}^+ + \mathcal{N}(A)$  是所有最小二乘解构成的集合。