

## Cremer-Rao 不等式简明讲稿

### ★ Score 函数、Score 统计量、Fisher 信息量

直观上看，如果一个事件发生的概率小，那么若它发生了就一定会给我们带来更多的信息。

若  $X_1, X_2, \dots, X_n$  为  $X \sim f(x; \theta)$  的一个样本，其观测值为  $x_1, x_2, \dots, x_n$ ，若  $\theta$  为参数的真值，则似然函数的值就大，即对数似然函数的导数应该接近于 0（大多数情况下，求 MLE 就是直接令对数似然函数的对参数的导数为 0 得到的）。

$$\text{记似然函数为 } L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i, \theta)$$

为方便起见，记  $\mathbf{x} = (x_1, x_2, \dots, x_n)$ ，则

$$\mathbf{X} = (X_1, X_2, \dots, X_n) \sim f(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta) = L(\theta; x_1, \dots, x_n) \quad (\text{注意分布与似}$$

然的关系)

称对数似然的导数（多个参数时为梯度）称为 **Score 函数**。

$$\text{Score 函数: } s(\mathbf{x}) = \frac{\partial}{\partial \theta} [\ln f(\mathbf{x}; \theta)] = \frac{\partial}{\partial \theta} [\ln L(\theta; \mathbf{x})]$$

**Score 统计量**:  $s(\mathbf{X})$  (其观测值为  $s(\mathbf{x})$ )。

**Score 函数** (或统计量) 具有如下性质:

$$(1) \quad s(\mathbf{x}) = \frac{\partial}{\partial \theta} [\ln f(\mathbf{x}; \theta)] = \frac{\partial}{\partial \theta} [\ln \prod_{i=1}^n f(x_i, \theta)] = \sum_{i=1}^n \frac{\partial}{\partial \theta} [\ln f(x_i, \theta)], \quad \text{这里 } f(x; \theta)$$

( $x$  是小写) 是总体的分布 (注意与样本的分布  $f(\mathbf{x}; \theta)$  的区别与联系)

(2) 期望  $E[s(\mathbf{X})] = 0$ ; 方差  $D[s(\mathbf{X})] = E[s^2(\mathbf{X})] \triangleq I_n(\theta)$  定义为  $\mathbf{X} = (X_1, X_2, \dots, X_n)$  的 **Fisher 信息量**。

$$\begin{aligned} E[s(\mathbf{X})] &= \int_{R^n} s(\mathbf{x}) f(\mathbf{x}, \theta) d\mathbf{x} = \int_{R^n} \frac{\partial}{\partial \theta} [\ln f(\mathbf{x}; \theta)] f(\mathbf{x}, \theta) d\mathbf{x} \\ &= \int_{R^n} \frac{\frac{\partial}{\partial \theta} f(\mathbf{x}; \theta)}{f(\mathbf{x}, \theta)} f(\mathbf{x}, \theta) d\mathbf{x} = \frac{\partial}{\partial \theta} \int_{R^n} f(\mathbf{x}, \theta) d\mathbf{x} = 0 \end{aligned}$$

**Fisher 信息量** 用来估计 MLE 的方程的方差。数据越多，该量越大，得到的信息越多。

(3) 如果二阶导数对一切  $\theta \in \Theta$  都存在，则

$$I_n(\theta) = D[s(\mathbf{X})] = E[s^2(\mathbf{X})] = -E\left[\frac{\partial^2}{\partial \theta^2} [\ln f(\mathbf{x}; \theta)]\right]$$

Fisher 信息量为对数似然在参数真值处的负二阶导数的期望，用来估计对数似然的曲率

Pf (上课略)：只给出一维情况，一般情形类似

$$\begin{aligned}
 0 &= \frac{\partial^2}{\partial \theta^2} \int_{-\infty}^{\infty} f(x; \theta) dx = \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} f(x; \theta) dx \\
 &= \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \left[ \frac{\partial \ln f(x; \theta)}{\partial \theta} f(x; \theta) \right] dx \\
 &= \int_{-\infty}^{\infty} \left[ \frac{\partial^2 \ln f(x; \theta)}{\partial \theta^2} f(x; \theta) + \frac{\partial \ln f(x; \theta)}{\partial \theta} \frac{\partial f(x; \theta)}{\partial \theta} \right] dx \\
 &= \int_{-\infty}^{\infty} \left[ \frac{\partial^2 \ln f(x; \theta)}{\partial \theta^2} \right] f(x; \theta) dx + \int_{-\infty}^{\infty} \left[ \frac{\partial \ln f(x; \theta)}{\partial \theta} \right]^2 f(x; \theta) dx \\
 &= E \left[ \frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right] + E \left[ \frac{\partial \ln f(X; \theta)}{\partial \theta} \right]^2 = E \left[ \frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right] + I(\theta)
 \end{aligned}$$

★ CRLB、有效估计

定理 (Cramer-Rao 不等式)：设样本  $(X_1, X_2, \dots, X_n) \triangleq \mathbf{X}$  的联合分布密度 (或分布律)

$f(\mathbf{x}; \theta)$ ,  $\theta \in \Theta \subset R$ , 满足 (对参数求导) 可交换条件：

$$\int_{R^n} \frac{\partial f(\mathbf{x}, \theta)}{\partial \theta} d\mathbf{x} = \frac{\partial}{\partial \theta} \int_{R^n} f(\mathbf{x}, \theta) d\mathbf{x}, \theta \in \Theta$$

(注：等式右边必为 0，理由密度函数积分为 1)

记  $T(\mathbf{X})$  为任方差有限的估计量，满足如下条件

$$\frac{\partial}{\partial \theta} [E(T(\mathbf{X}))] = \frac{\partial}{\partial \theta} \underbrace{\int_{R^n} T(\mathbf{x}) f(\mathbf{x}, \theta) d\mathbf{x}}_{\text{可交换求导}} = \int_{R^n} T(\mathbf{x}) \frac{\partial}{\partial \theta} f(\mathbf{x}, \theta) d\mathbf{x}, \theta \in \Theta$$

$$\text{则 } D(T(\mathbf{X})) \geq \frac{\left( \frac{\partial}{\partial \theta} [E(T(\mathbf{X}))] \right)^2}{I_n(\theta)}.$$

证明 (上课略)：Cauchy-Schwartz 不等式：  $DZ \geq \frac{(\text{Cov}(Z, Y))^2}{DY}$

$$\text{取 } Z = T(\mathbf{X}), Y = s(\mathbf{X}) = \frac{\partial}{\partial \theta} [\ln f(\mathbf{X}; \theta)]$$

$$EY = 0, DY = I_n(\theta)$$

由于

$$\text{Cov}(Z, Y) = E(ZY) = E(T(\mathbf{X})s(\mathbf{X})) = E(T(\mathbf{X}) \frac{\partial}{\partial \theta} [\ln f(\mathbf{X}; \theta)])$$

$$= \int_{R^n} T(\mathbf{x}) \frac{\partial}{\partial \theta} [\ln f(\mathbf{x}; \theta)] f(\mathbf{x}, \theta) d\mathbf{x}$$

$$= \int_{R^n} T(\mathbf{x}) \frac{\frac{\partial}{\partial \theta} f(\mathbf{x}; \theta)}{f(\mathbf{x}, \theta)} f(\mathbf{x}, \theta) d\mathbf{x} = \frac{\partial}{\partial \theta} \int_{R^n} T(\mathbf{x}) f(\mathbf{x}, \theta) d\mathbf{x}$$

$$= \frac{\partial}{\partial \theta} E(T(\mathbf{X}))$$

$$\text{故 } D(T(\mathbf{X})) \geq \frac{(\frac{\partial}{\partial \theta} [E(T(\mathbf{X}))])^2}{I_n(\theta)}。$$

注:

(1)  $I_n(\theta)$  是度量样本  $(X_1, X_2, \dots, X_n) \triangleq \mathbf{X}$  中含  $\theta$  的信息量,  $X_1$  的 Fisher 信息量是

$$I_1(\theta)。 I_1(\theta) = E[s^2(X_1)] = -E[\frac{\partial^2}{\partial \theta^2} [\ln f(x; \theta)]]$$

(2) 总体的两个独立样本  $\mathbf{X}, \mathbf{Y}$ , 则  $(\mathbf{X}, \mathbf{Y})$  的 Fisher 信息量为其各自 Fisher 信息量之和。

(3) (与教材上的定义的联系) 若总体  $X \sim f(x; \theta)$  的一个样本, 其 Fisher 信息量是

$$I_1(\theta) \text{ (同教材), 故 } X_1, X_2, \dots, X_n \text{ 的 Fisher 信息量 } I_n(\theta) = nI_1(\theta)。$$

$$\text{此时 } I_1(\theta) = E[s^2(X_1)] = E[(\frac{\partial}{\partial \theta} [\ln f(x; \theta)])^2] = -E[\frac{\partial^2}{\partial \theta^2} [\ln f(x; \theta)]]$$

该结论的另一证明 (略):

$$I_n(\theta) = E[s^2(\mathbf{X})] = E[(\frac{\partial}{\partial \theta} [\ln f(\mathbf{X}; \theta)])^2] = E[(\frac{\partial}{\partial \theta} [\ln \prod_{i=1}^n f(X_i; \theta)])^2]$$

$$= E[(\sum_{i=1}^n \frac{\partial}{\partial \theta} [\ln f(X_i; \theta)])^2]$$

$$= \sum_{i=1}^n E[(\frac{\partial}{\partial \theta} [\ln f(X_i; \theta)])^2] + 2 \sum_{i < j} E[\frac{\partial}{\partial \theta} \ln f(X_i; \theta) \frac{\partial}{\partial \theta} \ln f(X_j; \theta)]$$

$$= \sum_{i=1}^n E[(\frac{\partial}{\partial \theta} [\ln f(X_i; \theta)])^2] = nI_1(\theta)$$

(4) 与 MLE 联系 (不要求)  $\sqrt{n}(\hat{\theta}_{MLE} - \theta) \xrightarrow{D} N(0, \frac{1}{I_n(\theta)})$

(5) 若  $T(\mathbf{X})$  为  $g(\theta)$  的无偏估计, 即  $E(T(\mathbf{X})) = g(\theta)$ , 则

$$D(T(\mathbf{X})) \geq \frac{(g'(\theta))^2}{nI_1(\theta)} \quad (\text{即教材结果})$$

若无偏估计达到 CRLB, 则该估计称为有效估计, 故有效估计必为 UMVUE。

(6) (不要求) 多参量情况:  $\theta \in R^k$

$$D(T(\mathbf{X})) \geq \left( \frac{\partial}{\partial \theta} [E(T(\mathbf{X}))]^T [I_n(\theta)]^{-1} \frac{\partial}{\partial \theta} [E(T(\mathbf{X}))] \right)$$

$I_n(\theta) = E\left(\left(\frac{\partial}{\partial \theta} \ln f(\mathbf{x}; \theta)\right)\left(\frac{\partial}{\partial \theta} \ln f(\mathbf{x}; \theta)\right)^T\right)$  是  $k \times k$  Fisher 信息矩阵。

例: Poisson 总体  $X \sim P(\lambda)$ ,  $\bar{X}$  是  $\lambda$  的有效估计, 也是 UMVUE。

Pf: (这里用  $I_1(\lambda)$  计算, 注意  $I_n(\lambda) = nI_1(\lambda)$ )  $X \sim P(\lambda)$  的 p.m.f. 为

$$f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}, x = 0, 1, \dots \Rightarrow \ln f(x; \lambda) = \ln \frac{\lambda^x e^{-\lambda}}{x!} = x \ln \lambda - \lambda - \ln(x!)$$

$$\frac{\partial}{\partial \lambda} \ln f(x; \lambda) = \frac{x}{\lambda} - 1, \quad (= s(x))$$

$$\frac{\partial^2}{\partial \lambda^2} \ln f(x; \lambda) = -\frac{x}{\lambda^2}, \quad (= \frac{\partial}{\partial \lambda} s(x))$$

$$I_1(\lambda) = -E\left(\frac{\partial^2}{\partial \lambda^2} \ln f(X; \lambda)\right) = -E\left(-\frac{X}{\lambda^2}\right) = \frac{1}{\lambda}$$

故其 CRLB 为  $\frac{1}{nI_1(\lambda)} = \frac{\lambda}{n}$

由于  $E(\bar{X}) = \lambda, D(\bar{X}) = \frac{\lambda}{n}$ , 达到 CRLB, 故是有效估计, 也是 UMVUE。

例: 均匀总体  $U(0, \theta)$  的有关问题,  $f(x; \theta) = \frac{1}{\theta} 1_{\{0 < x < \theta\}}$

直接计算如下:  $\frac{\partial}{\partial \theta} \ln f(x; \theta) = -\frac{1}{\theta} \Rightarrow I_1(\theta) = E\left[\left(\frac{\partial}{\partial \theta} \ln f(X; \theta)\right)^2\right] = \frac{1}{\theta^2}$

$$\text{CRLB 应为 } \frac{1}{nI_1(\theta)} = \frac{\theta^2}{n}$$

前面的课上，我们已经证明了  $\frac{n+1}{n} X_{(n)}$  为  $\theta$  的无偏估计，且

$$D\left(\frac{n+1}{n} X_{(n)}\right) = \frac{\theta^2}{n(n+2)} < \frac{\theta^2}{n} = \text{CRLB}$$

问题出在哪里：（对参数求导的可交换性不满足，CR 定理不能用），事实上

$$\begin{aligned} \frac{d}{d\theta} \int_0^\theta t(x) f(x; \theta) dx &= \frac{d}{d\theta} \int_0^\theta t(x) \frac{1}{\theta} dx = \frac{t(\theta)}{\theta} + \int_0^\theta t(x) \frac{d}{d\theta} \left(\frac{1}{\theta}\right) dx \\ &\neq \int_0^\theta t(x) \frac{d}{d\theta} f(x; \theta) dx \end{aligned}$$

注：

(1) 一般若 p.d.f 的支撑集依赖于待估参数，可交换条件不满足，不能用 Cramer-Rao 定理。好在于若是指数族分布，均可以满足，即可以直接用 Cramer-Rao 定理。

(2) 上例中  $\frac{n+1}{n} X_{(n)}$  确为  $\theta$  的 UMVUE，事实上， $X_{(n)}$  为  $\theta$  的充分统计量，且其分布

密度为

$$f_{X_{(n)}}(x) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 < x < \theta, \\ 0, & \text{elsewhere.} \end{cases}$$

该分布族是完备的，因为根据完备的定义，只需证明： $X \sim f_{X_{(n)}}(x)$ ，若当

$E(g(X)) = 0$  时必有  $P(g(X) = 0) = 1$ ，由于

$$\begin{aligned} E(g(X)) &= \int_0^\theta g(x) \frac{nx^{n-1}}{\theta^n} dx = 0, \forall \theta > 0 \\ &\Leftrightarrow \int_0^\theta g(x) x^{n-1} dx = 0, \forall \theta > 0 \end{aligned}$$

两边对  $\theta$  求导得， $g(\theta)\theta^{n-1} = 0$ ，故  $g(\theta) = 0, \forall \theta > 0$ ，从而完备，又由于

$E\left(\frac{n+1}{n} X_{(n)}\right) = \theta$ （无偏），因此由 Lemann-Scheffe 定理知， $\theta$  的 UMVUE 为

$$E\left(\frac{n+1}{n} X_{(n)} \mid X_{(n)}\right) = \frac{n+1}{n} X_{(n)}$$

(3) 关于完备统计量，我们有如下定理：  
定理：若总体的分布是指数族分布，即

$$f(x; \boldsymbol{\theta}) = h(x)c(\boldsymbol{\theta}) \exp\left\{\sum_{j=1}^k w(\theta_j)T_j(x)\right\}, \boldsymbol{\theta} = (\theta_1, \dots, \theta_k) \in \Theta$$

则只要参数空间  $\Theta$  包含  $R^k$  中的一个开集，则统计量

$$\left(\sum_{i=1}^n T_1(X_i), \sum_{i=1}^n T_2(X_i), \dots, \sum_{i=1}^n T_k(X_i)\right) \text{ 是完备统计量。}$$